

AI Engineer Journey — Terimler ve Kısa Kullanım Notları

Repo çalışmalarından çıkarılmış kişisel başvuru notu · 26 Temmuz 2026

Bu belgede yalnızca repoda çalıştığım veya deneyle kullandığım kavramlar var. Her maddede terimin kısa anlamı, nerede işe yaradığı ve küçük bir örnek bulunuyor. Amaç formül ezberlemek değil; ileride bir ML, LLM veya RAG sistemi kurarken doğru kavramı doğru yerde hatırlamak.

1. Yazılım ve çalışma düzeni

- **CLI / terminal:** Programları grafik arayüz yerine komutlarla çalıştırdığım ortamdır. Otomasyon, test ve sunucu işleri için kullanılır. Örnek: `pytest -q` ile tüm testleri tek komutla çalıştırmak.
- **Mutlak ve görelî yol:** Mutlak yol dosyanın sistemdeki tam adresidir; görelî yol bulunduğum klasöre göre hesaplanır. Örnek: `/home/alperen/ai-engineering-journey` mutlak, `docs/report.md` görelî yoldur.
- **Shell script:** Tekrar eden terminal komutlarını bir dosyada toplar. Kurulum veya kontrol adımlarını unutmayı azaltır. Örnek: haftalık testleri çalıştıran `run_week1_checks.sh`.
- **Virtual environment:** Python paketlerini sistemden ve diğer projelerden ayırır. Sürüm çakışmasını önler. Örnek: bu projenin `.venv` ortamına `sentence-transformers` kurulması.
- **Dependency:** Kodun çalışmak için kullandığı dış pakettir. Sürümü ve amacı bilinmelidir. Örnek: PDF metni okumak için `pypdf`, embedding için `sentence-transformers`.
- **Module / package / import:** Module tek Python dosyası, package ilişkili modüllerin klasörüdür; import bunları kullanıma alır. Örnek: `labs.rag.reranker` modülündeki sınıfı PDF deneyinde kullanmak.
- **OOP:** Veriyi ve o veriyle ilgili davranışları sınıflarda toplama yaklaşımıdır. Karmaşık AI uygulamalarında bileşen sınırlarını netleştirir. Örnek: bir `Milestone` nesnesinin kendi ilerleme doğrulamasını taşıması.
- **Dataclass:** Veri taşıyan Python sınıflarını daha kısa ve açık yazmayı sağlar. Örnek: arama sonucunda `chunk_id`, metin ve skoru birlikte tutan sonuç nesnesi.
- **Enum:** Bir alanın alabileceği sınırlı değerleri tanımlar. Yazım hatalarını ve geçersiz durumları azaltır. Örnek: artifact türünün rastgele metin yerine önceden tanımlı değerlerden seçilmesi.
- **Validation:** Veri sisteme girmeden önce kurallara uygunluğunu kontrol eder. Hatanın daha erken ve anlaşılır çıkmasını sağlar. Örnek: `top_k` değerinin sıfırdan büyük olmasını zorunlu tutmak.
- **Unicode / text normalization:** Metni karşılaştırmadan önce büyük-küçük harf, noktalama ve Unicode birleşik işaretlerini tutarlı hale getirmektir. Türkçe `İlk` ifadesinin casefold sonrası `i` + nokta işaretine ayrılması, evaluator'ın doğru cevabı yanlış saymasına yol açtı; bu yüzden normalizasyon da test edilir.
- **Type hint:** Fonksiyonun hangi veri tipini alıp döndürdüğünü açıklar. Büyük pipeline'larda yanlış bileşen bağlantılarını erken fark ettirir. Örnek: arama fonksiyonunun `list[ChunkSearchResult]` döndürmesi.

- **mypy:** Kodu çalıştırmadan type hint uyumsuzluklarını kontrol eder. Örnek: reranker'ın beklediği aday tipiyle vector store çıktısının uyuştüğünü doğrulamak.
- **Unit test / pytest:** Küçük bir davranışın beklenen sonucu verdiğini otomatik kontrol eder. Örnek: boş aday listesinde reranker'ın boş sonuç döndürmesi.
- **Mock / fake bileşen:** Testte ağır model veya dış servisin yerine kontrollü sahte nesne kullanılır. Test hızlı ve deterministik olur. Örnek: gerçek cross-encoder indirmeden PDF reranking veri akışını test etmek.
- **Refactor:** Davranışı değiştirmeden kodun yapısını iyileştirmektir. Örnek: tekrar eden validation kurallarını ortak yardımcı fonksiyona çıkarmak.
- **Logging ve debugging:** Logging çalışma sırasında olayları kaydeder; debugging hatanın nerede ve neden oluştuğunu araştırır. Örnek: model yüklenirken veya retrieval sonucu beklenmedik olduğunda ara değerleri görmek.
- **Profiling ve benchmark:** Profiling zamanın hangi fonksiyonlarda harcadığını, benchmark ise belirli işlemin süresini ölçer. Örnek: saf Python matris çarpımıyla NumPy sürümünü karşılaştırmak.
- **Git branch / commit / Pull Request:** Branch değişikliği ana koddan ayırır, commit anlamlı bir kayıt oluşturur, PR değişikliğin incelenip birleştirilmesini sağlar. Bu geçmiş yapılan işi kanıtlar ve geri izlemeyi kolaylaştırır.
- **Conventional Commit:** Commit mesajını `type(scope): açıklama` biçiminde standardize eder. Örnek: `feat(rag): rerank PDF retrieval candidates.`
- **Artifact ve reproducibility:** Artifact yapılan işin görünür çıktısıdır; reproducibility aynı ayarlarla deneyin yeniden üretilebilmesidir. Kod, test, JSON sonucu ve raporu birlikte saklamak bu nedenle önemlidir.

2. Matematik, veri ve hazırlama

- **Scalar, vector ve dimension:** Scalar tek sayıdır; vector sıralı sayılar listesidir; dimension listedeki sayı adedidir. Örnek: bir cümle embedding'i 384 sayıdan oluşuyorsa 384 boyutludur.
- **Dot product:** İki vektörün karşılıklı elemanlarını çarpıp toplar. Benzer yönleri ölçen cosine similarity hesabının temel parçalarından biridir.
- **Norm:** Vektörün uzunluğunu hesaplar. Cosine similarity'de vektör büyüklüğünün sonucu yanıtmasını önlemek için kullanılır.
- **Cosine similarity:** İki vektör arasındaki açının benzerliğini ölçer; yön aynılaştıkça skor 1'e yaklaşır. RAG'de soru embedding'iyile chunk embedding'ini karşılaştırmak için kullanılır. Yüksek skor tek başına "bu parça soruyu cevaplar" demek değildir.
- **Matrix:** Satır ve sütunlardan oluşan sayı tablosudur. Transformer ağırlıkları ve toplu embedding işlemleri matris işlemleriyle yürür.
- **Transpose ve matrix multiplication:** Transpose satırlarla sütunları değiştirir; matris çarpımı bir temsili başka boyuta dönüştürür. Attention'daki query-key skorları da matris çarpımlarıyla hesaplanır.
- **Sparse vector:** Elemanlarının çoğu sıfır olan vektördür. Kelime tabanlı TF-IDF gösterimi buna örnektir; sözlük büyür ama bir metin yalnız az sayıda kelime içerir.
- **Dense vector:** Çoğu elemanı dolu olan sabit boyutlu vektördür. Sentence Transformer'ın ürettiği 384 sayılık cümle embedding'i buna örnektir.

- **DataFrame ve Series:** pandas'ta DataFrame satır-sütun tablosu, Series tek sütunluk dizidir. CSV yükleme, eksik değer kontrolü ve feature hazırlamada kullanılır.
- **Raw ve processed data:** Raw data kaynaktan geldiği ilk haldir; processed data temizlenip model kullanımına hazırlanmıştır. Ham veri doğrudan modele verilmemelidir.
- **Missing value ve imputation:** Missing value eksik veridir; imputation bunu bir kuralla doldurur. Örnek: Titanic yaş bilgisini genel ortalama yerine unvan, sınıf ve cinsiyet grubuna göre tahmin etmek.
- **EDA:** Exploratory Data Analysis, model kurmadan önce veri dağılımını, eksikleri ve ilişkileri incelemektir. Amaç "veri ne söylüyor?" sorusuna raporla cevap vermektir.
- **SQL:** Veritabanından doğru satırları seçmek, filtrelemek, sıralamak ve gruplamak için kullanılır. Örnek: `GROUP BY` ile bir grubun ortalama başarı değerini bulmak.
- **Feature (X) ve target (y):** Feature modelin girdisi, target öğrenmeye çalıştığı sonuçtur. Titanic'te yaş, sınıf ve cinsiyet X; hayatta kalma y'dir.
- **Train/test split:** Verinin bir bölümü öğrenme, görülmemiş bölümü değerlendirme için ayrılır. Test verisine bakarak karar vermek gerçek performansı bozar.
- **Numerical ve categorical feature:** Numerical sayısal ölçüm, categorical sınırlı kategori bilgisidir. Yaş sayısal; biniş limanı veya unvan kategoriktir.
- **Encoding ve scaling:** Encoding kategorileri modele uygun sayılara dönüştürür; scaling sayısal sütunları karşılaştırılabilir ölçeğe getirir. Logistic Regression pipeline'ında preprocessing parçasıdır.
- **Pipeline:** Veri hazırlama ve model adımlarını aynı sırada bağlar. Örnek: eksik doldurma → one-hot encoding → model. Eğitim ve tahminde aynı işlemlerin uygulanmasını sağlar.
- **Data leakage:** Modelin normalde tahmin anında bilemeyeceği bilgiyi eğitimde görmesidir. Örnek: tüm veri üzerinde imputation hesaplayıp sonra cross-validation yapmak skoru yapay olarak yükseltebilir.

3. Makine öğrenmesi ve deney değerlendirme

- **Baseline:** Daha gelişmiş yöntemleri kıyaslamak için kurulan ilk basit çalışan modeldir. İyileştirmenin gerçekten değerli olup olmadığını baseline'a göre ölçeriz.
- **Classification:** Girdiyi sınıflardan birine atama problemidir. Örnek: öğrencinin başarılı/başarısız veya Titanic yolcusunun hayatta kaldı/kalmadı tahmini.
- **Logistic Regression:** Sınıf olasılığı üreten sade ve yorumlanabilir bir baseline modelidir. Karmaşık modelden önce veri pipeline'ının çalıştığını göstermek için uygundur.
- **Random Forest:** Birçok karar ağacının tahminini birleştirir. Doğrusal olmayan ilişkileri yakalayabilir; fakat daha büyük ve daha az yorumlanabilir olabilir.
- **Histogram Gradient Boosting:** Hataları sırayla düzelten ağaç tabanlı güçlü bir model ailesidir. Titanic model karşılaştırmasında aynı feature setinde en yüksek yerel CV ortalamasını verdi.
- **Accuracy:** Tüm tahminlerin ne kadarının doğru olduğunu ölçer. Sınıflar dengesizse tek başına yanıltıcı olabilir.
- **Precision:** Modelin pozitif dediği örneklerin ne kadarının gerçekten pozitif olduğunu ölçer. Yanlış cevap vermenin pahalı olduğu RAG no-answer kararlarında önemlidir.

- **Recall:** Gerçek pozitif örneklerin ne kadarını yakaladığımızı ölçer. Cevaplanabilir soruları gereksiz reddetmemek istediğimizde önemlidir.
- **F1 score:** Precision ve recall arasında denge kurar. Tek metrik kullanmak gerekirse iki hata türünü birlikte gözetir.
- **True/false positive ve true/false negative:** Kararların dört temel sonucudur. RAG örneği: kaynakta olmayan hava durumu sorusuna cevap vermek false positive; kaynakta olan venv sorusunu reddetmek false negative'dir.
- **Cross-validation:** Veriyi farklı train/validation parçalarına bölerek modeli birkaç kez ölçer. Tek şanslı bölünmeye güvenmeyi azaltır.
- **Stratified K-Fold:** Her fold'da sınıf oranlarını yaklaşık koruyan cross-validation türüdür. Titanic gibi sınıflandırma problemlerinde kullanıldı.
- **Repeated cross-validation:** Cross-validation'ı farklı bölünmelerle tekrarlar. Küçük veri setinde sonucun ne kadar kararlı olduğunu daha iyi gösterir.
- **Mean ve standard deviation:** CV mean ortalama performansı, CV std fold'lar arasındaki oynaklığı gösterir. Bir modelin ortalaması yüksek ama std'si çok büyükse kararsız olabilir.
- **Random seed:** Rastgele işlemleri tekrar üretilebilir yapar. Örnek: `random_state=42` kullanarak aynı veri bölünmesini elde etmek.
- **Feature engineering:** Ham sütunlardan probleme daha anlamlı yeni özellikler üretmektir. Örnek: isimden `Title`, aile üyelerinden `FamilySize` oluşturmak.
- **Hyperparameter:** Modelin veriden öğrenmediği, deneyi yapanın seçtiği ayardır. Örnek: ağaç derinliği, regularization gücü veya retrieval'daki top-k.
- **Ablation study:** Bir özelliği veya bileşeni çıkarıp sonucun nasıl değiştiğini ölçer. Titanic deneyinde iyileşmenin çoğunu `Title` özelliğinin getirdiği bu şekilde görüldü.
- **Controlled comparison:** Tek seferde yalnız bir değişkeni değiştiririz. Örnek: aynı feature, aynı CV, farklı model; böylece farkın modelden geldiğini söyleyebiliriz.
- **Experiment logging:** Modeli, ayarları, metrikleri ve notları her deneyde kaydetmektir. Aynı deneyi tekrarlamayı ve yalnız iyi sonuçları hatırlama hatasını önler.
- **Out-of-fold prediction:** Her satır için o satırı eğitimde görmeyen fold modelinin ürettiği tahmindir. Daha dürüst hata analizi ve ensemble çalışmaları için kullanılır.
- **Ensemble:** Birden fazla modelin tahminini birleştirir. Modeller farklı hatalar yapıyorsa tek modelden daha kararlı olabilir; benzer modelleri toplamak otomatik olarak fayda sağlamaz.
- **Error analysis:** Yalnız skora değil, hangi satırların neden yanlış tahmin edildiğine bakmaktır. Yeni feature fikri veya veri sorunu buradan çıkar.
- **Overfitting:** Modelin eğitim veya yerel validation ayrıntılarını ezberleyip yeni veride kötüleşmesidir. Çok sayıda deneyi yalnız public leaderboard'a göre seçmek de leaderboard overfitting oluşturabilir.
- **Negative result:** Beklenen iyileşmenin oluşmaması da sonuçtur. Örnek: yeni feature CV'yi artırmıyorsa saklanır ve neden fayda vermediği raporlanır.
- **Risky flip guard:** Yeni modelin eski tahminden değiştirdiği satırları inceleyen güvenlik kontrolüdür. Toplam skor artmış görünse bile riskli değişiklikleri körlemesine göndermemeyi sağlar.

4. LLM ve Transformer temelleri

- **Tokenizer:** Ham metni modelin sözlüğündeki parçalara böler. Model kelimeleri doğrudan değil, bu token dizisini işler.
- **Subword token:** Kelimeden küçük, karakterden büyük tekrar kullanılabilir parçadır. Türkçedeki ekleri ve sözlükte olmayan kelimeleri yönetmeye yardımcı olur.
- **Token ID:** Tokenın sözlükteki sıra numarasıdır; tek başına anlam taşımaz. Anlamli sayısal temsil embedding tablosundan alınır.
- **Token embedding:** Her token ID'sini öğrenilmiş sayılar dizisine dönüştürür. LLM katmanları bu vektörler üzerinde işlem yapar; sentence embedding ile aynı amaçta değildir.
- **Position bilgisi:** Aynı tokenların farklı sırada oluşunu ayırt etmek için dizideki konumu temsile ekler. "Köpek adamı ısırdı" ile "adam köpeği ısırdı" bu nedenle aynı değildir.
- **Transformer:** Token temsillerini attention ve MLP katmanlarıyla tekrar tekrar güncelleyen model mimarisidir. Modern LLM'lerin temelidir.
- **Self-attention:** Her tokenın aynı metindeki diğer görünür tokenlardan ne kadar bilgi alacağını hesaplar. "Onu" gibi bir tokenın hangi önceki kişiye bağlandığını bağlama göre kurmaya çalışır.
- **Query, Key, Value:** Attention'ın üç temsilidir. Query "hangi bilgiye ihtiyacım var?", Key "bende hangi bilgi var?", Value "eşleşirsek aktaracağım içerik" şeklinde düşünülebilir.
- **Causal mask:** Sıradaki token tahmin edilirken gelecekteki tokenların görünmesini engeller. Böylece model eğitimde cevabın devamını gizlice okuyamaz.
- **Residual connection, normalization ve MLP:** Residual önceki bilgiyi taşır, normalization sayısal akışı dengeler, MLP her token temsilini dönüştürür. Transformer block yalnız attention'dan oluşmaz.
- **Next-token prediction:** LLM, bağlama göre bir sonraki tokenın olasılıklarını üretir ve seçilen tokenı dizinin sonuna ekler. Akıcı metin üretmesi otomatik olarak doğru bilgi verdiği anlamına gelmez.
- **Context window:** Modelin tek istekte görebildiği toplam token sınırıdır. System prompt, sohbet geçmiş, RAG chunkları, soru ve üretilecek cevap aynı bütçeyi paylaşır.
- **Token budget:** Context window içinde hangi parçaya ne kadar alan ayrıldığını anlatır. Çok fazla ilgisiz chunk eklemek cevaba yer bırakmayabilir ve modeli dağıtabilir.
- **System prompt ve user message:** System uygulamanın genel davranış talimatını, user mevcut isteği taşır. Ancak gerçek öncelik modelin chat template'ine ve uygulama katmanına da bağlıdır; system prompt tek başına güvenlik duvarı değildir.
- **Chat template:** System, user ve assistant mesajlarının modele gönderilmeden önce hangi özel tokenlarla birleştirileceğini belirler. Aynı prompt farklı template'te farklı davranabilir.
- **Base model:** Esas olarak sonraki token tahmini için eğitilmiş ham modeldir. Tamamlama, araştırma ve fine-tuning için uygundur; doğrudan sohbet talimatlarına her zaman iyi uymaz.
- **Instruct model:** Kullanıcı talimatlarını izleme ve sohbet formatında cevap verme için ayrıca eğitilmiş modeldir. Yerel asistan veya RAG cevaplayıcı için genellikle base modelden daha uygundur.
- **Parameter count:** Modelde öğrenilmiş ağırlık sayısıdır. Daha fazla parametre kapasiteyi artırabilir ama "her görevde daha iyi" garantisi vermez; RAM ve gecikme maliyeti de yükselir.
- **Quantization:** Model ağırlıklarını daha düşük hassasiyetle saklayarak RAM kullanımını azaltır. 32 GB RAM'li, GPU'suz bilgisayarda 4B sınıfı modelleri çalıştırmayı kolaylaştırır; küçük bir kalite kaybı olabilir.

- **Temperature ve deterministik ayar:** Temperature yükseldikçe örnekleme çeşitlenir; düşük değer daha tutarlı sonuç verir. Prompt sürümlerini karşılaştırırken aynı ayar ve düşük rastgelelik kullanmak gerekir.
- **Cold ve warm latency:** Cold latency model ilk yüklenirken geçen süreyi, warm latency model bellekteyken sonraki istek süresini anlatır. Yerel model karşılaştırmasında ikisi ayrı ölçülmelidir.
- **Local inference:** Modelin bulut API yerine kendi bilgisayarında çalışmasıdır. Veri kontrolü sağlar; donanım sınırı, RAM ve hız sorumluluğu bana geçer.
- **Cold start / warm start:** Cold start, model ağırlıkları ilk kez RAM'e yüklenirken yapılan ilk çağrıdır; warm start model zaten yüklüyken sonraki çağrıdır. Yerel Gemma deneyinde soğuk ve sıcak süreleri ayrı yorumlamazsak vector DB gecikmesini yanlış ölçebiliriz.
- **Thinking token ve görünür cevap:** Bazı reasoning modelleri token bütçesinin bir bölümünü iç düşünmeye harcar. API'de bu düşünce ayrı alan olarak gelebilir veya yanlış template ile görünür metne karışabilir; `num_predict` biterse kullanıcıya final cevap hiç dönmeyebilir.
- **Serving / template uyumu:** Aynı model ağırlıkları farklı chat template, system prompt veya thinking ayarıyla bambaşka ürün davranışı verebilir. Qwen deneyi, model seçiminin yalnız ağırlık seçmek değil, doğru serving konfigürasyonunu da ölçmek olduğunu gösterdi.
- **Ollama ve Open WebUI:** Ollama yerel modeli indirip servis eder; Open WebUI tarayıcıdan sohbet arayüzü sağlar. Arayüz model değildir, yalnız modele erişim katmanıdır.
- **Prompt injection:** Kullanıcı veya doküman içeriğinin “önceki kuralları yok say” gibi talimatlarla sistemi yönlendirmeye çalışmasıdır. Sadece prompt yazarak tamamen çözülemez; uygulama izinleri ve çıktı kontrolleri gerekir.
- **Hallucination:** Modelin akıcı ama kaynaksız veya yanlış bilgi üretmesidir. V2 promptunun kaynakta olmayan izin süresini söylemesi buna örnektir.
- **Prompt evaluation:** Prompt değişikliğini birkaç sabit vakada ölçmektir. V1 aşırı reddetti, V2 cevapladı ama yanlış çıkarım yaptı, V3 özellik-değer bağıını koruyarak daha iyi denge kurdu; V4 üslubu düzeltirken no-answer davranışını bozdu.
- **Model selection:** Model yalnız benchmark veya parametre sayısına göre seçilmez. Lisans, Türkçe ve kod performansı, RAM, gecikme, quantization, context ve yerel görev testleri birlikte değerlendirilir.

5. Embedding, retrieval ve RAG

- **RAG:** Retrieval-Augmented Generation, cevap üretmeden önce dış dokümanlardan kanıt bulup modele bağlam olarak verme yaklaşımıdır. Amaç modelin yalnız ezberine güvenmemektir.
- **Document:** Sisteme giren anlamlı kaynak birimidir. PDF, politika metni veya teknik doküman bir document olabilir; kimlik, başlık, kaynak ve metin taşır.
- **Ingestion:** Kaynağı okuyup normalize ederek RAG sisteminin kullanacağı document/chunk yapısına dönüştürme sürecidir. Örnek: PDF'den seçilebilir metni `pypdf` ile çıkarmak.
- **Structured / section-aware ingestion:** PDF'i yalnız düz metin değil, mantıksal başlık ve bölüm yapısıyla sisteme almaktır. Mentor PDF'inde `04 Yerel modeli...` ve `Teslim Paketi` başlıklarını chunk metadata'sına taşıyınca doğru bölümün adaylara girme oranı iyileşti.
- **Document-specific parser:** Belirli bir belge ailesinin bilinen başlık, tablo veya üst bilgi kurallarını kullanan parser'dır. Güçlü olabilir ama genelleştirilmemelidir; örnek: bu mentor PDF'inin yedi bilinen başlığını configuration olarak vermek ve farklı PDF türünde ayrı test etmek.

- **Chunk:** Uzun dokümanın retrieval için ayrılmış küçük parçasıdır. Chunk her zaman “bir dosya” değildir; dosyanın birkaç cümlesi veya belirli token aralığı olabilir.
- **Overlap:** Komşu chunkların bir miktar ortak metin taşımasıdır. Bilginin chunk sınırında ikiye ayrılmasını azaltır. Örnek: 2 cümlelik chunkta 1 cümle overlap.
- **Metadata:** Chunk metnine eklenen sayfa, başlık, bölüm, tarih veya kaynak bilgisidir. Doğru filtreleme, kaynak gösterme ve daha isabetli retrieval için kullanılır.
- **Chunk-size trade-off:** Küçük chunk daha nokta atışı olabilir ama bağlamı eksiltebilir; büyük chunk daha fazla bağlam taşır ama genel metinle skoru şişirebilir. Mentor PDF’inde 2 cümlelik chunk, amaç sorusunda 5 cümlelik chunktan daha isabetliydi.
- **Vectorization:** Metni matematiksel olarak karşılaştırılabilir sayı temsiline çevirme işlemidir. TF-IDF de embedding de vectorization yapar; çalışma mantıkları farklıdır.
- **Term Frequency:** Bir kelimenin dokümanda kaç kez geçtiğini ölçer. “Python” kelimesi iki kez geçiyorsa o terimin frekansı buna göre artar; anlamdaş kelimeleri anlayamaz.
- **IDF:** Her yerde geçen kelimelerin önemini azaltıp nadir kelimelerin önemini artırır. “ve” düşük, “venv” daha yüksek ayırt edici ağırlık alabilir.
- **TF-IDF:** Kelimenin ilgili belgede sık, tüm koleksiyonda ise nadir olmasını ödüllendiren sparse gösterimdir. Tam teknik terim ve ürün kodu aramalarında güçlüdür.
- **Lexical retrieval:** Kelime veya parça eşleşmesine dayalı aramadır. “python -m venv” gibi exact ifadeleri iyi yakalar; farklı kelimelerle aynı anlamı bulmakta zorlanabilir.
- **Sentence embedding:** Cümle veya paragrafın genel anlamını sabit boyutlu dense vektöre çevirir. Kullandığımız çok dilli MiniLM modeli her metin için 384 sayı üretir.
- **384 dimension:** Cümlelerin 384 ayrı insan-tanımlı özelliği demek değildir. Modelin eğitim sırasında faydalı bulunduğu dağıtık sayısal temsil alanıdır; tek bir sayıya “bu Python anlamıdır” diyemeyiz.
- **Bi-encoder:** Soru ve chunkları birbirinden bağımsız embed eder. Chunk vektörleri önceden hesaplanabildiği için çok sayıda metinde hızlı candidate search yapılır.
- **Semantic search:** Aynı kelimeler geçmese de anlamı yakın metinleri embedding ile bulur. Örnek: “sanal ortam oluşturma” sorgusunun “venv kurulumu” parçasını getirmesi.
- **Vector store:** Chunkları, embeddinglerini ve metadata’yı saklayıp benzerlik araması yapan katmandır. Repoda önce in-memory sürümü kuruldu; Chroma/Qdrant gibi kalıcı ürünler aynı temel ihtiyacı daha büyük ölçekte çözer.
- **Vector database:** Vektörleri ve metadata’yı kalıcı, client/server tabanlı bir collection içinde saklayan vector store türüdür. In-memory liste süreç kapanınca kaybolur; Qdrant gibi bir DB ile PDF chunkları yeniden başlatmada da aranabilir kalır.
- **Collection:** Aynı embedding boyutu ve şemaya sahip vektör kayıtlarının mantıksal grubudur. Örnek: mentor PDF’inin 384 boyutlu chunk embeddingleri için tek bir Qdrant collection.
- **Payload / metadata filtering:** Vektörün yanında saklanan, aramayı daraltan alanlardır. Örnek: yalnız `section_id=local_model` olan chunklarda arama yapmak veya cevaba doğru source bilgisini eklemek.
- **Upsert:** Kimliği daha önce yoksa kayıt ekleme, varsa aynı kaydı güncelleme işlemidir. Mentor PDF’i ikinci kez ingest edilince 48 chunk’ın 96’ya çıkmaması upsert sayesinde.
- **Idempotency:** Aynı işlemi birden fazla kez uygulamanın aynı nihai durumu üretmesidir. İndeksleme hata sonrası tekrar çalıştırılabildiği için RAG ingestion’ında kritik bir güvenilirlik özelliğidir.

- **Persistent volume:** Container silinse veya yeniden başlatılsa bile veriyi container dışındaki bağlı diskte saklayan volume'dür. Qdrant'ın named volume'u restart sonrasında 48 point'in korunmasını sağladı.
- **RAG orchestration:** Retrieval, reranking, context builder, no-answer policy ve LLM çağrısını doğru sırayla birleştiren uygulama katmanıdır. Her bileşen tek başına çalışsa bile bu sıra kurulmazsa kanıtın nerede kaybolduğu anlaşılamaz.
- **Threshold calibration:** "Hangi retrieval skoru yeterli kanıt demektir?" sorusunu sabit vakalarda ölçerek yanıtlama sürecidir. Başka bir veri setindeki 0.50 eşikliğini yeni PDF'e doğrudan taşımak false negative üretebilir.
- **Self-hosted ve managed service:** Self-hosted servisi kendi Docker/sunucunda işletmektir; managed serviste sağlayıcı operasyonu yönetir. İlkinde veri kontrolü ve operasyon sorumluluğu, ikincisinde kolaylık ve sağlayıcı/maliyet bağımlılığı trade-off'u vardır.
- **Retrieval:** Soruya en ilgili document veya chunk adaylarını bulma aşamasıdır. İyi LLM yanlış chunklarla doğru cevap veremez; RAG kalitesinin ilk kapısıdır.
- **Top-k:** Retrieval'ın döndüreceği en yüksek skorlu aday sayısıdır. `top_k=5`, en iyi beş chunkı sonraki aşamaya geçirir. Çok düşük k doğru kanıtı kaçırabilir, çok yüksek k gürültü ve maliyet getirir.
- **Candidate generation:** Hızlı retrieval ile küçük bir aday kümesi oluşturma aşamasıdır. Reranker yalnız bu adaylar arasından seçebilir; doğru parça top-k'ya girmediyse onu geri getiremez.
- **Hybrid retrieval:** Lexical ve semantic skorları birleştirir. Böylece hem exact anahtar kelimeyi hem paraphrase anlamını yakalamaya çalışır.
- **Score normalization ve weight:** Farklı retriever skorlarını aynı aralığa getirip ne kadar etkili olacaklarını ayarlarız. Örnek: `0.6 dense + 0.4 lexical`; en iyi ağırlık varsayımla değil eval setiyle seçilir.
- **Reranker / cross-encoder:** Soru ve her adayı birlikte okuyup daha hassas relevance skoru üretir. Pahalı olduğu için tüm koleksiyona değil top-k adaylara uygulanır.
- **PDF reranking örneği:** "Teslim paketinde ne var?" sorusunda doğru tablo parçası dense sıralamada 5. adaydı; cross-encoder onu 1. sıraya taşıdı. Yerel model sorusunda doğru bölüm top-5'e girmediği için reranker düzeltmedi.
- **Context builder:** Seçilen chunkları kaynak bilgileriyle düzenleyip LLM'e verilecek bağlamı hazırlar. Sıra, ayırıcılar ve token bütçesi burada yönetilir.
- **Context budget:** LLM'e gönderilecek kanıt için koyduğumuz karakter veya token üst sınırıdır. Gereğinden çok context gecikmeyi artırır ve modelin dikkatini dağıtabilir; az context ise cevabı eksik bırakabilir.
- **Small-to-big retrieval / parent-section expansion:** Küçük child chunklarla doğru yeri bulup, cevap üretirken bağlı olduğu daha geniş parent section'ı kullanma desenidir. Yerel model ölçüm sorusunda tek chunk no-answer verirken tam `local_model` section'ı doğru metrikleri içeren cevap üretti.
- **Grounded answer:** Cevabın verilen kanıtı dayandırmasıdır. Model yalnız contextte bulunan bilgiyi söylemeli ve mümkünse kaynağı göstermelidir.
- **Evidence filtering:** Skoru çok zayıf chunkların context'e girmesini engeller. İlgisiz kanıt modelin uydurma yapmasını kolaylaştırabilir.
- **Answerability:** Bulunan kanıtın soruyu gerçekten cevaplamaya yetip yetmediği karardır. Semantik yakınlıkla aynı değildir: "izin süresi" parçası "izin talebi ne zaman yapılır?" sorusuna yakın olabilir ama doğru özelliği cevaplamaz.

- **Threshold:** Cevap vermek için gereken minimum skor sınırıdır. Çok düşük threshold false positive, çok yüksek threshold false negative üretir; sabit eval vakalarıyla ayarlanmalıdır.
- **Score margin:** Birinci ve ikinci aday arasındaki farktır. En iyi skor yüksek görünse bile ikinci adayla fark çok küçükse sistem kararsız olabilir.
- **Answerability profile:** Loose, balanced veya conservative gibi farklı threshold politikalarıdır. Riskli kurumsal kullanımda conservative profil daha çok reddedebilir; yardım odaklı sistem daha dengeli profil seçebilir.
- **No-answer detection:** Yeterli kanıt yoksa cevap üretmek yerine “yeterli bağlam yok” deme yoludur. Similarity skorunu teknik sayıdan ürün kararına dönüştürür.
- **Golden query:** Beklenen doğru document/chunk bilgisi önceden etiketlenmiş test sorusudur. Retriever değişikliklerini aynı sorular üzerinde adil biçimde ölçmek için kullanılır.
- **Rank:** Beklenen doğru sonucun listede kaçınıcı sırada olduğunu gösterir. Rank 1 en iyi durumdur; sonuç top-k içinde yoksa rank bulunamaz.
- **Hit@1 ve Hit@K:** Hit@1 doğru cevabın ilk sırada, Hit@K ilk k sonuç içinde bulunma oranıdır. Reranker kullanılacaksa Hit@K candidate kalitesini, son cevap için Hit@1 hassasiyeti gösterir.
- **Reciprocal Rank ve MRR:** Doğru sonucun sırası r ise reciprocal rank $1/r$ 'dir; MRR tüm soruların ortalamasıdır. Doğru sonucu üst sıralara getiren sistemi ödüllendirir.
- **Retrieval benchmark:** Retriever'ı kolay ve zor golden query setinde düzenli ölçmektir. Yalnız birkaç güzel demo sorusu sistemin güvenilir olduğunu kanıtlamaz.
- **Paraphrase robustness:** Aynı niyet farklı kelimelerle sorulduğunda sistemin davranışını korumasıdır. Dense embedding lexical yöntemine göre bu konuda genellikle daha güçlüdür; yine de ölçülmelidir.
- **Repeatability:** Aynı soru ve ayarlarda sonucun tekrarlar boyunca ne kadar kararlı olduğudur. Yerel Gemma V3 promptu 8 vaka $\times$ 3 tekrarda denenerek küçük ölçeekte kontrol edildi.

6. Kurduğum zihinsel akış

Veri/ML: ham veri → temizlik → EDA → feature/target → preprocessing pipeline → baseline → cross-validation → feature/model deneyi → hata analizi → kayıtlı karar.

LLM: metin → token → token ID → token + position embedding → Transformer katmanları → sıradaki token olasılıkları → üretilen cevap.

RAG: kaynak → ingestion → document → chunk + metadata → sparse/dense embedding → vector store → top-k retrieval → hybrid/reranking → evidence filtering → answerability → context → LLM cevabı veya no-answer.

Genel mühendislik kuralım: Çalışan çıktı tek başına yeterli değildir. Varsayımı yaz, ölçümü sabitle, hatayı saklama, başarısız deneyi kaydet, testi çalıştır ve kararı kanıtlarla.